

第四讲 - 参数估计 (Lecture 4: Parameter Estimation)

总结笔记

1. 参数估计的方法 (Methods of Estimation)

1.1 核心概念

- **参数 (Parameter)**: 描述一个总体分布的数值特征, 在频率学派中通常是未知但固定的常量 (例如: μ, p, λ)。

- **统计量 (Statistic)**: 样本数据的任意函数。因为其值依赖于抽取的样本, 所以它是一个随机变量。

- **估计量 (Estimator)**: 用于估计未知参数的统计量, 它是一个规则或函数 (例如: $\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n X_i$)。

- **估计值 (Estimate)**: 估计量根据具体样本计算出的特定数值 (例如: $\hat{\mu} = 175.3 \text{ cm}$)。

1.2 矩估计法 (Method of Moments - MoM)

- **核心思想**: 令样本矩等于理论矩, 然后求解方程得到参数的估计量。

- k 阶理论矩: $m_k = \mathbb{E}[X^k]$ 。

- k 阶样本矩: $\hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 。

- **示例**:

- **伯努利分布 (Bernoulli)**: 参数为 p 的伯努利分布, 其矩估计量为样本均值 $\hat{p}_{MoM} = \bar{X}_n$ 。

- **指数分布 (Exponential)**: 参数为 λ 的指数分布, 其矩估计量为样本均值的倒数 $\hat{\lambda}_{MoM} = \frac{1}{\bar{X}_n}$ 。

1.3 最大似然估计法 (Maximum Likelihood Estimation - MLE)

- 核心思想: 寻找能使观测到的样本数据出现概率最大的那个参数值。
 - 关键函数:
 - 似然函数 (Likelihood): $L(\theta|x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$ 。
 - 对数似然函数 (Log-Likelihood): $l(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$ 。最大化对数似然函数通常更简单, 因为对数是单调函数。
 - 示例:
 - 伯努利分布 (Bernoulli): $\hat{p}_{MLE} = \frac{k}{n} = \bar{X}_n$, 即样本成功率。
 - 正态分布 (Normal): $\hat{\mu}_{MLE} = \bar{X}_n$ 和 $\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ 。
 - MLE 不变性 (Invariance Property): 如果 $\hat{\theta}$ 是 θ 的 MLE, 那么 $g(\hat{\theta})$ 就是 $g(\theta)$ 的 MLE。
-

2. 评估估计量 (Evaluating Estimators)

2.1 偏差 (Bias)

- 定义: 估计量的期望值与真实参数的差值, $Bias(\hat{\theta}) = E[\hat{\theta}] - \theta$ 。
- 无偏估计量 (Unbiased Estimator): 偏差为零的估计量, 即 $E[\hat{\theta}] = \theta$ 。
- 重要例子:
 - 正态分布方差的 MLE ($\hat{\sigma}_{MLE}^2$) 是有偏的, 它会系统性地低估真实方差, 其期望为 $E[\hat{\sigma}_{MLE}^2] = \frac{n-1}{n} \sigma^2$ 。
 - 常用的无偏样本方差 (variance) 是经过贝塞尔校正 (Bessel's correction) 的 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ 。

2.2 均方误差 (MSE) 与 偏见-方差权衡 (Bias-Variance Tradeoff)

- 定义: 均方误差 (MSE) 是衡量估计量优劣的综合指标, 定义为 $MSE(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2]$ 。
- MSE 分解: $MSE(\hat{\theta}) = Var(\hat{\theta}) + (Bias(\hat{\theta}))^2$ 。
- 偏见-方差权衡:
 - 有时, 接受一点偏差可以换来方差的大幅降低, 从而获得更低的整体 MSE。
 - 在估计硬币概率的例子中, 当真实概率 p 处于中间范围时, 有偏的“收缩”估计量 $\hat{p}_B$ 的 MSE 低于无偏的 MLE 估计量 $\hat{p}_A$ 。
 - 这个原理是机器学习中正则化技术 (如 Ridge 和 Lasso 回归) 的核心, 即通过引入偏差来控制模型方差, 防止过拟合。

2.3 一致性 (Consistency)

- 定义: 随着样本量 n 的增加, 估计量 $\hat{\theta}_n$ 会依概率收敛于真实参数 θ ($\hat{\theta}_n \xrightarrow{p} \theta$)。
 - 重要结论:
 - 根据大数定律 (Weak Law of Large Numbers), 样本均值 $\bar{X}_n$ 是总体均值 μ 的一致估计量。
 - 连续映射定理 (CMT): 如果 X_n 依概率收敛于常数 c , 且函数 g 在 c 点连续, 那么 $g(X_n)$ 也依概率收敛于 $g(c)$ 。
 - 无偏样本方差 S^2 和指数分布的矩估计量 $\hat{\lambda}_{MOM}$ 都是一致估计量。
 - 最大似然估计量 (MLE) 通常也具有 consistency。
-

3. 克拉美-罗下界 (The Cramér-Rao Lower Bound - CRLB)

3.1 核心问题

• CRLB 回答了这个问题：一个无偏估计量的方差最小能达到多少？。它为任何无偏估计量的方差设定了一个理论下限。

3.2 费雪信息 (Fisher Information)

• 定义: 衡量单次观测中包含的关于未知参数 θ 的信息量，记为 $I(\theta)$ 。

• 计算公式:

• $I(\theta) = \mathbb{E}[(\frac{\partial}{\partial \theta} \log f(X; \theta))^2]$ (得分函数的方差)。

• 或 $I(\theta) = -\mathbb{E}[\frac{\partial^2}{\partial \theta^2} \log f(X; \theta)]$ (对数似然函数二阶导的负期望)。

• 样本信息: 对于 n 个独立同分布的样本，总费雪信息为 $I_n(\theta) = n \cdot I(\theta)$ 。

3.3 CRLB 定理与有效估计量

• CRLB 定理: 对于任何无偏估计量 $\hat{\theta}$ ，其方差满足 $\text{Var}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}$ 。

• 有效估计量 (Efficient Estimator): 如果一个无偏估计量的方差达到了 CRLB，即 $\text{Var}(\hat{\theta}) = \frac{1}{I_n(\theta)}$ ，则称其为有效估计量。

• 重要例子:

• 对于正态分布 $N(\mu, \sigma^2)$ (已知 σ^2)，样本均值 $\bar{X}_n$ 是 μ 的一个有效估计量。

• 它的方差 $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$ 恰好等于该问题的 CRLB。

• 因此，它是最优的无偏估计量。